



Prédire la probabilité de résiliation d'un contrat d'assurance auto

Cette présentation explore la prédiction de la résiliation de contrats d'assurance auto. Nous aborderons le contexte concurrentiel, les défis liés aux données et les stratégies de modélisation. L'objectif est **d'aider les petites compagnies d'assurance auto** à anticiper et à prévenir la perte de clients.

Contexte et Objectifs

Contexte

Les compagnies d'assurance auto opèrent dans **un environnement concurrentiel**. L'acquisition et la fidélisation des clients sont cruciales. Les données aident à comprendre le comportement des clients et à prévenir les résiliations.



Objectifs

Prédire la probabilité de résiliation permet d'agir en amont.

Les gros assureurs ont l'avantage d'avoir des millions de clients qui rendent l'analyse complexe ou alors ils rachètent des données.

L'objectif est de mettre en place des stratégies pour retenir les clients à risque pour une petite société nouvelle sur le marché en prenant en compte l'aspect RGPD.

Challenges

On travaille sur 2 datasets :

- On modélise sur un dataset simulé
- On a le dataset avec la data réelle
- **Challenge 1** : Les modèles de machine learning peuvent mal généraliser.
- **Challenge 2** : Le dataset simulé contient des millions d'observations.
- **Challenge 3** : Correspondance difficile entre les features de datasets différents.

Sources de données



1

Data simulée

Données relationnelles avec 4 tables joignables. Contient plus de 2 millions de clients. Environ 10% des clients ont résilié leurs contrats.

<https://www.kaggle.com/datasets/merishnasuwal/auto-insurance-churn-analysis-dataset/data?select=address.csv>

2

Data Hackathon

Dataset avec des features anonymisées (feature_1, feature_2...). Transformation inconnue des données. Nécessité d'établir une correspondance avec les données simulées.

<https://www.kaggle.com/datasets/k123vinod/insurance-churn-prediction-weekend-hackathon?resource=download>

Plan de travail



Reconstitution

Jointure des tables.

A close-up of a computer monitor displaying a large data table with many columns and rows of numerical data. The table appears to be a result of a data join operation.


Nettoyage

Comparaison des distributions.



Modélisation

Tester et évaluer des modèles.



Généralisation

Déployer la meilleure version.

Environnement Technique : MLFlow, Streamlit, Sklearn, Dask

Nettoyage des données

1 Analyse

Visualisation des taux de nulls, NA, et entropie par colonne.

2 Suppression

Suppression des features à entropie trop élevée ou faible.
Suppression des valeurs aberrantes (âge > 100 ans).

3 Encodage

Encodage des variables avec un pipeline (Binary, Ordinal, BaseN, TargetEncoder).

	COUNTY_0	MARITAL_STATUS_0	CITY_0	HOME_MARKET_VALUE	churn	CURR_ANN_AMT	DAYS_TENURE	AGE_IN_YEARS	INCOME	HAS_CHILDREN	LENGTH_OF_RESIDENCE	HOME_OWNER	COLLEGE_DEGREE	GOOD_CREDIT	LATITUDE	LONG
count	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593	1975593
mean	3.4084	1.7285	18.8729	5.0587	0.1207	928.4736	3399.0012	53.2393	81464.2675	0.4435	6.5967	0.6895	0.2974	0.8186	32.8489	-96.8489
std	2.044	0.7912	19.7886	3.4031	0.3258	243.05	2299.5751	11.2032	49989.95	0.4968	5.0013	0.4627	0.4571	0.3853	0.1729	0.1729
min	1	1	1	-1	0	-213.0367	20	23.472	5000	0	0	0	0	0	31.9864	-96.8489
25%	2	1	4	3	0	762.7832	1204	45.473	52500	0	2	0	0	1	32.74	-96.8489
50%	3	2	12	5	0	923.2957	3247	55.444	80372.176	0	6	1	0	1	32.8488	-96.8489
75%	4	2	26	7	0	1088.6949	6068	59.305	87500	1	10	1	1	1	32.9379	-96.8489
max	15	3	96	19	1	2261.3608	6291	79.305	250000	1	15	1	1	1	33.5466	-96.8489

Création de la variable cible




Définition

Création de la variable cible à partir de la date de résiliation.

1 si date existe, 0 sinon.

Exemple : Âge

Transformation et analyse de la variable âge.



Modèles de prédiction

Type

Problème de classification binaire.
Ré équilibrage des classes.



Objectifs

Minimiser les faux négatifs (FNR). Maximiser le recall en gardant une bonne précision.


Métriques

Suivi du FPR, FNR, et des courbes précision-recall.

Run name	learning_rate	num_features	num_leaves	num_samples	n_estimators	test_shape	test_size	train_shape	accuracy	bin_cross_ent	↓ f1-score
smote-augmentation-sacling-rfcv	--	15	--	3474226	--	(694846, 15)	0.2	(2779380, 15)	0.8885	4.0192	0.8829
rus-scaling-and-LogisticRegression	--	15	--	476960	--	(95392, 15)	0.2	(381568, 15)	0.6346	13.1699	0.648
rus-scaling-and-LogisticRegression_v2-wo_coord	--	13	--	476960	--	(95392, 13)	0.2	(381568, 13)	0.637	13.0856	0.6473
rus-scaling-and-AdaBoost	--	15	--	476960	500	(95392, 15)	0.2	(381568, 15)	0.7002	10.8049	0.6275
rus-scaling-and-AdaBoost_v2-wo_coord	--	13	--	476960	25	(95392, 13)	0.2	(381568, 13)	0.7002	10.8046	0.6275
rus-scaling-and-GradientBoosting_v2-wo_coord	--	13	--	476960	100	(95392, 13)	0.2	(381568, 13)	0.7053	10.6205	0.6261
rus-scaling-and-GradientBoosting	--	15	--	476960	100	(95392, 15)	0.2	(381568, 15)	0.7051	10.6296	0.6259
rus-scaling-and-LightGBM_v2-wo_coord	0.1	13	50	476960	75	(95392, 13)	0.2	(381568, 13)	0.7078	10.5302	0.6257
rus-scaling-and-KNeighbors	--	15	--	476960	--	(95392, 15)	0.2	(381568, 15)	0.7003	10.8008	0.6242
rus-scaling-and-RandomForest	--	15	--	476960	200	(95392, 15)	0.2	(381568, 15)	0.704	10.6682	0.6222



On arrive à augmenter la capacité du modèle à prédire les vrais positifs en utilisant l'oversampling avec SMOTE plutôt que le Random Under Sampling



Les features les plus importantes sont :

- Le fait que l'assuré ait un enfant, le fait qu'il ait un diplôme de niveau sup., qu'il soit propriétaire etc..
- Ces variables représentent de grands changements dans la vie des personnes
- Il faudrait que les sociétés d'assurance accompagnent les personnes dans les étapes clés de leurs vies.

Généralisation



Test de KS

Comparaison des distributions simulées et réelles. Détermine si les échantillons proviennent de la même distribution.

Exemple :

La variable target réelle correspond probablement à churn : p_value du test : 0.744 (KS stat = 0.0037)



Hypothèse nulle

Les deux échantillons proviennent de la même distribution.



Application

Comparer des distributions simulées et réelles.



Conclusion

Données simulées

Les données simulées fournissent une base pour la modélisation initiale.

Facteurs importants dans la résil : *a un enfant, a un diplôme d'étude sup, durée du contrat.*

Limites

Manque de preuves statistiques pour affirmer que les features des datasets proviennent de la même distribution.

Data drift

Présence de nouvelles features ou data drift. Le modèle ne peut pas être généralisé à ces nouvelles données.